Практическое занятие 7

Очистка и преобразование признаков доставки

Цель работы — подготовить признаки для прогноза задержки более чем на 15 минут в момент создания заказа. Получены матрицы train, validation и test одинаковой ширины — 16 столбцов. Параметры импутации, масштабирования и кодирования оценены только по train.

Исходные данные и разделение

Исходный orders_dirty.csv содержит 600 строк и 10 полей. Удалены один полный дубликат и одна запись с конфликтом исторической метки; осталось 598 уникальных заказов. Метка проверена по правилу late = 1, если actual_minutes − promised_minutes > 15. Исходный файл сохранён без изменений, что подтверждено SHA-256.

В предоставленном CSV отсутствует courier_load, поэтому этот признак исключён из шаблона. Присутствующий vehicle_type не добавлялся к заданному набору X. Словарь полей взят из занятия 6 с тем же исходным CSV. Числовые поля: distance_km, queue_size и promised_minutes; категории: zone и weather; created_at используется для производных часа.

Цель y — late. Идентификатор order_id используется только для проверки разделения и сопоставления строк. actual_minutes известен после доставки и запрещён как предиктор. Все шесть входных полей X доступны при создании заказа.

Выборка	N	Задержки	Доля задержек
train	358	168	46.93%
val	120	56	46.67%
test	120	56	46.67%

Сохранены принадлежности заказов из 06_stratified_splits.csv: стратификация по late, random_state=42, приблизительно 60/20/20. Название validation приведено к val. Проверены отсутствие пересечений ID, полнота объединения и сумма размеров. Разделение предшествует всем обучаемым преобразованиям.

Полный код и результаты находятся в 07_student.ipynb. Состав и порядок исходных 13 ячеек сохранены. Окружение Python 3.12 размещено в .venv в корне проекта; точные версии зависимостей записаны в requirements.txt.

Аудит качества и выбор импутации

Числовые строки преобразованы через to_numeric с errors="coerce". Отрицательные значения и нулевая обещанная длительность считаются пропусками. Пробельные и словесные маркеры отсутствия в категориях приведены к NaN. Нечисловое расстояние обнаружено в одной строке train и одной val; отрицательных значений, недопустимых нулей и дробных значений целочисленных полей не обнаружено.

Поле	Train 358	Val 120	Test 120
distance_km	1 (0.3%)	1 (0.8%)	0 (0.0%)
queue_size	1 (0.3%)	0 (0.0%)	0 (0.0%)
promised_minutes	0 (0.0%)	0 (0.0%)	0 (0.0%)
zone	0 (0.0%)	0 (0.0%)	0 (0.0%)
weather	0 (0.0%)	1 (0.8%)	0 (0.0%)

В таблице указаны количество и доля пропусков после фиксированных исправлений типов. Для planned_speed_kmh пропуски совпадают с отсутствующим расстоянием; временные производные пропусков не имеют. Полный аудит всех 10 исходных полей и трёх производных сохранён в 07_missing_audit.csv. Поля вне X включены только для контроля качества; статистики категорий приведены отдельно.

Поле	n	Min	Медиана	Среднее	Max
distance_km	357	1.0	8.5	8.829	52.8
queue_size	357	0.0	10.0	10.283	22.0
promised_minutes	358	21.0	49.5	50.031	84.0

Для distance_km среднее 8,829 км превышает медиану 8,5 км при диапазоне 1–52,8 км. Медиана меньше зависит от редких больших расстояний. Для queue_size среднее 10,283 и медиана 10 при диапазоне 0–22: разница невелика, но медиана даёт устойчивое типичное целое значение нагрузки. Это обоснование устойчивости, а не доказательство улучшения качества будущей модели.

Для расстояния Q1 = 4,3, Q3 = 12,7, IQR = 8,4 км; пороги равны −8,3 и 25,3 км. Значение 52,8 выходит за верхний порог и обычный диапазон словаря 0,5–20 км, но словарь запрещает автоматическое удаление. Такие строки сохранены. Очередь укладывается в допустимые 0–30; обещанное время — положительное целое.

Для шести числовых признаков использована медиана train с add_indicator=True. Три индикатора относятся к distance_km, queue_size и planned_speed_kmh. Собственный индикатор отсутствия расстояния точно совпал с автоматическим на всех выборках, в том числе после стандартизации; повторный столбец не добавлен.

Масштабирование и конструирование признаков

Признак	Медиана	Среднее scaler	Масштаб scaler
distance_km	8.5000	8.8285	5.4792
queue_size	10.0000	10.2821	6.2397
promised_minutes	49.5000	50.0307	14.6471
hour_sin	0.0000	-0.0295	0.7093
hour_cos	-0.0000	-0.0226	0.7039
planned_speed_kmh	10.0000	9.8115	4.9803

Параметры сверены с прямыми расчётами: imputer.statistics_ = медианы F_train; scaler.mean_ и scaler.var_ = средние и дисперсии импутированной train-матрицы (ddof=0). Подстановка 10^9 в расстояния validation с последующим transform не изменила обученные параметры. Все параметры, включая индикаторы, сохранены в 07_transform_parameters.csv.

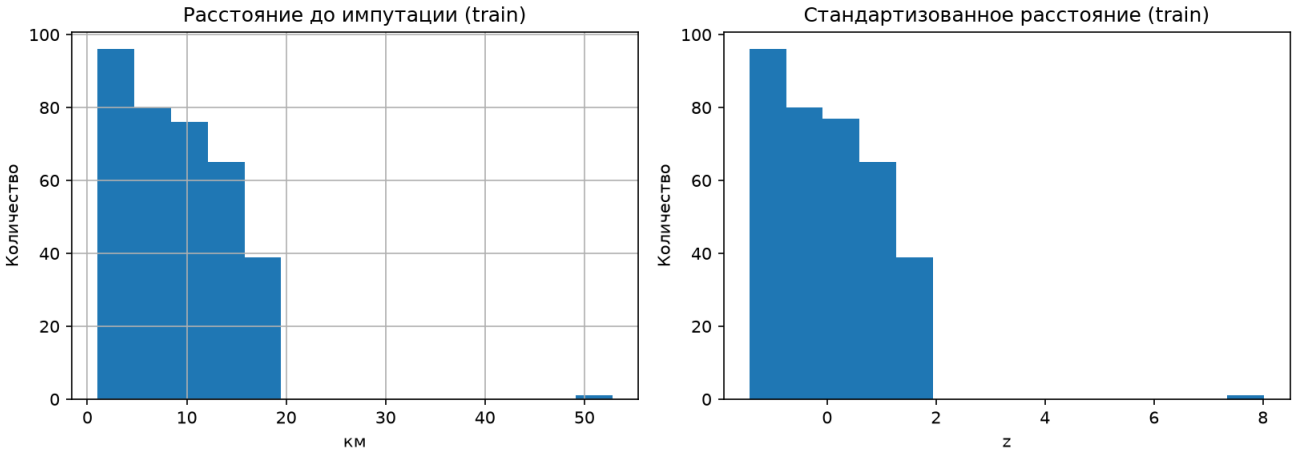


Рисунок 1 — распределение расстояния train до импутации (слева). Рисунок 2 — расстояние после импутации и стандартизации (справа). Большое расстояние сохранено; стандартизация меняет масштаб, но не устраняет выброс. Пропуск заменяется медианой, поэтому справа учитываются все 358 строк.

Стандартизация: $z = (x - \mu_{train}) / \sigma_{train}$. Для расстояния $\mu = 8{,}828492$, $\sigma = 5{,}479217$. Отличие от исходного среднего объясняется импутацией. MinMaxScaler использует минимум и размах train, здесь 1 и 51,8 км; значения отложенной выборки могут выходить за [0, 1]. Z-оценка не ограничена этим интервалом.

Час заменён парой $\sin(2\pi h/24)$, $\cos(2\pi h/24)$. Для 23:00, 00:00 и 01:00 координаты равны (−0,259; 0,966), (0; 1), (0,259; 0,966). Расстояния между соседними парами равны примерно 0,261 вместо 23 и 1 у простого часа. Переход через полночь больше не создаёт искусственного скачка.

Плановая скорость равна $60 \cdot \text{distance_km} / \text{promised_minutes}$ при положительном обещанном времени. Она доступна при создании заказа и не использует actual_minutes. Это характеристика плана, а не фактическая скорость курьера.

Кодирование категорий и контрольные выводы

One-Hot обучен только на train: zone даёт четыре столбца (center, east, north, south), weather — три (clear, rain, snow). Категориальные пропуски заменяются константой «неизвестно». В train таких пропусков нет, поэтому пропуск погоды в val тоже обрабатывается как неизвестная категория.

Стадия	Число столбцов
Входные поля	6
После конструирования	8
Числовые с индикаторами	9
One-Hot	7
Итог	16

Все семь выходных полей One-Hot: zone_center, zone_east, zone_north, zone_south, weather_clear, weather_rain, weather_snow. Полная схема из 16 признаков сохранена в 07_feature_schema.csv. Итог: шесть числовых признаков, три индикатора и семь категориальных индикаторов.

Зона __НОВАЯ_ЗОНА__ закодирована четырьмя нулями, блок weather остался неизменным; число выходных полей не изменилось. Это обеспечено handle_unknown="ignore". Информация о специфике новой зоны теряется, поэтому успешный transform не означает, что модель знает эту зону.

Ответы на контрольные вопросы

1. Среднее всей таблицы зависит от отложенных наблюдений и переносит сведения о них в обучение даже без использования y. 2. IQR — эвристика: корректные дальние заказы также могут выходить за пороги. 3. StandardScaler использует среднее и стандартное отклонение, MinMaxScaler — минимум и размах train.

4. Размерность One-Hot равна сумме чисел категорий, найденных в train: здесь 4 + 3 = 7 вместо двух исходных полей. 5. actual_minutes запрещён в X, поскольку он известен после события и определяет метку. 6. Часы 23 и 0 близки, потому что разделены одним часом; циклическая пара сохраняет это соседство.

Три ошибки: импутация до разделения вызывает утечку статистик; отдельный fit One-Hot на каждой выборке нарушает согласованность столбцов; добавление actual_minutes использует недоступное будущее. Все три ситуации исключены выбранной последовательностью подготовки.

Вывод

Создана рабочая копия с проверенными метками и уникальными ID. Разбиение из предыдущей работы сохранено. Нечисловые значения и пропуски обработаны по явным правилам. Медианы и параметры масштабирования получены только из train. One-Hot сохраняет схему при неизвестных категориях, но теряет их специфику. Циклическое время и плановая скорость используют только доступные при заказе сведения. Итоговые матрицы размером 358×16, 120×16 и 120×16 конечны, а исходный CSV не изменён.